Aceleración CUDA y regímenes empíricos de profundidad de parada en efectos olvidados max–min

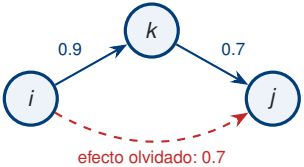
forgethreads: max–min con memoria cuadrática en GPU

Carlos Riquelme-Ávila **Julio Rojas-Mora** **Elliott Mardones-Arias**

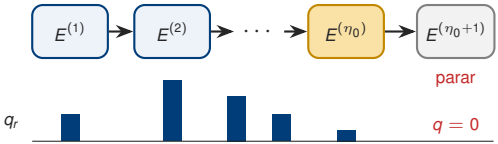
Universidad Católica de Temuco, Chile

Jornadas Chilenas de Computación (JCC) 2026

El problema: efectos olvidados y el orden de detención



no está en E; aparece por un camino



Ingeniería

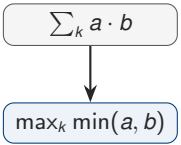
Cada orden cuesta $\mathcal{O}(N^3)$. ¿Cómo escalar?

Ciencia

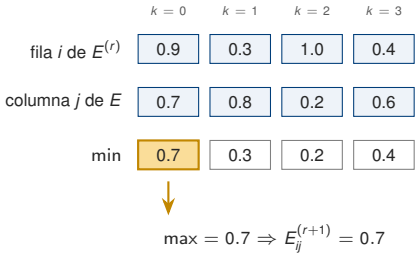
¿De qué depende el orden de detención η_0?

La composición max–min

$$E_{ij}^{(r+1)} = \max_k \ \min\left(E_{ik}^{(r)}, E_{kj}\right)$$

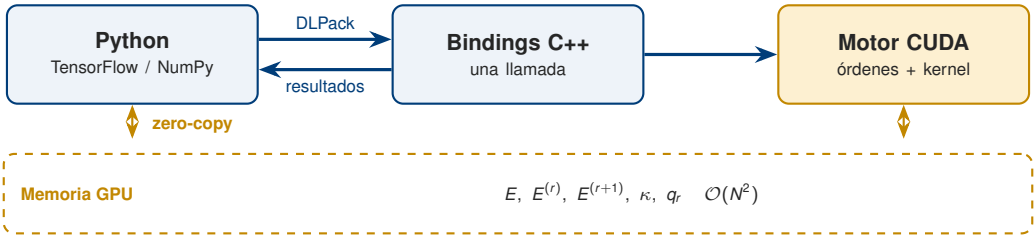


Es un **GEMM** con otras operaciones.



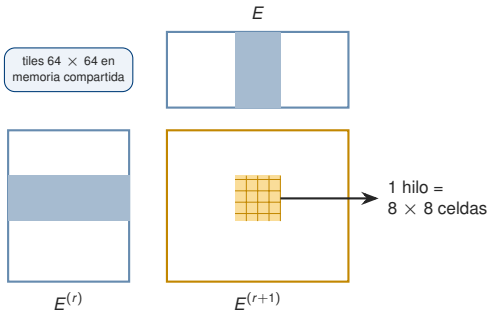
Arista más débil (min), mejor camino (max).
N^2 celdas $\times$ N candidatos $= \mathcal{O}(N^3)$ por orden.

Arquitectura de forgethreads



Los tensores se comparten por puntero: **sin copias** host–GPU.
Se itera hasta $q_r = 0$ y se devuelven los efectos, q_r y η_0.

Kernel: tiling estilo GEMM + conteo

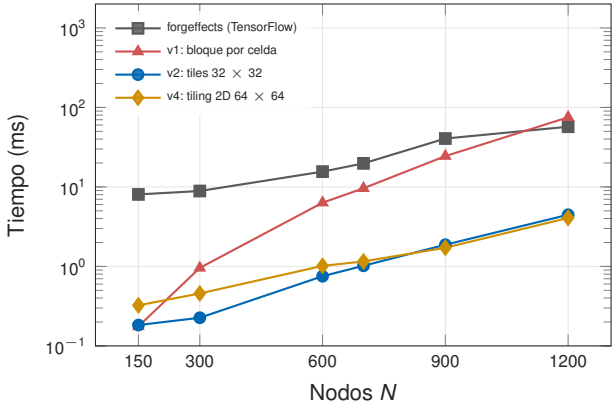


	GEMM	max–min
operación	$a \cdot b$	min
acumulador	$+$	max
epílogo	$\alpha AB + \beta C$	**¿$\Delta \geq \epsilon$?** $\rightarrow q_r$ **+1**

Lo nuevo

q_r se cuenta **en la misma pasada**, con un contador atómico.

Rendimiento y límites en una RTX 4090



`float16`, 3 órdenes, media de 10 ejecuciones.

Speedup frente a forgeffects

v2: 12.8–44×

v4: 14–25×

Tamaño máximo (24 GB)

forgeffects: 1 200 (OOM en 1 300)

forgethreads: 32 000

1k 10k 32k

forgeffects es útil, pero su memoria crece como N^3.

Profundidad de parada: un recurso finito

$$q_r = \#\{(i,j) : \Delta_{ij}^{(r)} > \epsilon\}$$

$$\eta_0 = \max\{r : q_r > 0\}$$

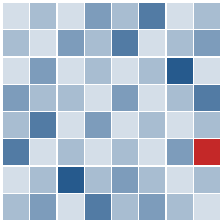
Con $\epsilon = 1/2$

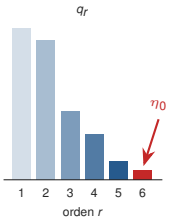
Cada par se descubre **una sola vez**: dos saltos $> \frac{1}{2}$ superarían 1.

$\Rightarrow \sum_r q_r \leq N^2$

η_0 = orden en que se gasta el **último** par.

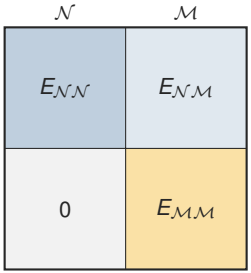
cada par (i, j): el orden en que se descubre





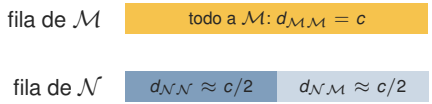
(esquema ilustrativo)

Diseño: dos bloques, un parámetro c

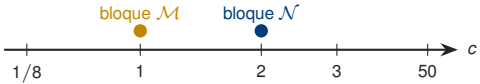


solo $\mathcal{N} \to \mathcal{M}$ · binaria

c = grado de salida esperado por fila

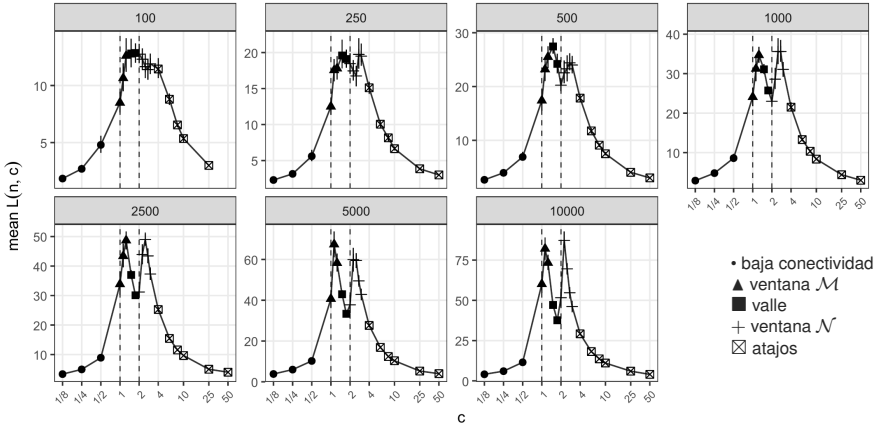


Cada bloque llega a **grado 1** en un c distinto:



7 tamaños ($n \leq 10\,000$) $\times$ 19 valores de c $\times$ 20 réplicas = **2 640 grafos**

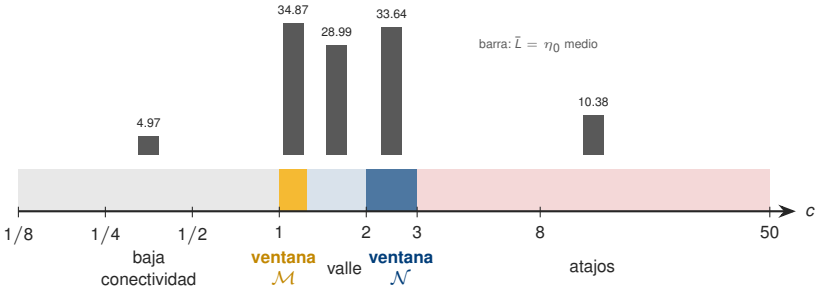
Resultado: un perfil de dos ventanas



Más conexiones no implican más órdenes: **bajo** → **pico** → **valle** → **pico** → **caída**.

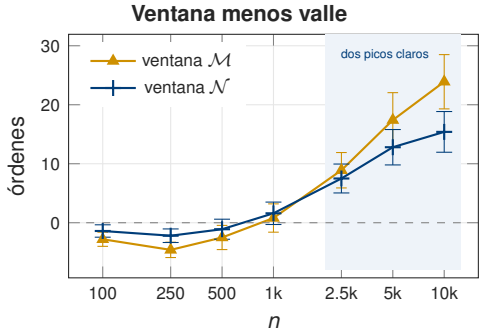
Un panel por tamaño n. Barras: intervalo de confianza 95 % (bootstrap). Líneas punteadas: $c = 1$ y $c = 2$.

Cinco regímenes

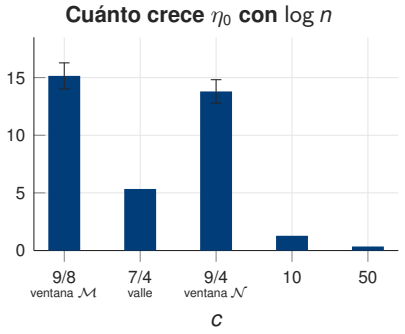


Baja conectividad	cadenas cortas: se agotan pronto
Ventana $\mathcal{M}$	$\mathcal{M}$ en su umbral: cadenas largas y frágiles
Valle	$\mathcal{M}$ ya tiene atajos; $\mathcal{N}$ aún no llega
Ventana $\mathcal{N}$	$\mathcal{N}$ en su umbral
Atajos	muchos caminos cortos: todo se descubre temprano

Las dos ventanas se marcan más al crecer n



Desde $n = 2\,500$ ambas ventanas superan al valle.



En las ventanas crece **casi 3 veces** más rápido que en el valle.

Barras de error: intervalo de confianza 95 % (bootstrap).

Conclusiones

1. Más conexiones no implican más órdenes.
2. Picos donde cada bloque llega a grado 1: $c = 1$ ($\mathcal{M}$) y $c \approx 2$ ($\mathcal{N}$).
3. El patrón se marca más al crecer n.
4. **forgethreads**: memoria $\mathcal{O}(N^2)$, hasta 44× más rápido y 32 000 nodos.

Trabajo futuro

- η_0 por bloque
- pesos difusos (max–T)
- teoría de regímenes
- kernels dispersos

¡Gracias!

¿Preguntas?

criquelme2022@alu.uct.cl · julio.rojas@uct.cl · elliott.mardones@uct.cl

github.com/criquelme2003/feCUDA